

Rapport

Module : traitement de la parole : synthèse vocale

Filière : 2^{ème} Année cycle d'ingénierie en Intelligence Artificielle

Semestre : 8

Date : 20/04/2025

TP : Identification et vérification du locuteur

Encadré par :

- Pr. Jamal Kharroubi

Réalisé par :

- Wiame Adnane

Sommaire

- | 01 Introduction**
Page : 3
- | 02 Présentation de la base de données**
Page : 4
- | 03 Prétraitement des données audio**
Page : 4
- | 04 Modélisation par GMM : Entraînement**
Page : 5
- | 05 Evaluation : Identification du Locuteur**
Page : 6
- | 06 Evaluation : Vérification du Locuteur**
Page : 11
- | 07 Conclusion**
Page : 17

1. Introduction

L'**identification** et la **vérification** du locuteur sont des tâches fondamentales en traitement automatique de la parole, avec des applications critiques dans des domaines tels que la sécurité biométrique, l'authentification vocale, et les systèmes interactifs intelligents. Ces technologies reposent sur l'analyse des caractéristiques vocales uniques à chaque individu, souvent modélisées à l'aide de techniques avancées d'apprentissage automatique.

Dans ce projet, nous nous concentrons sur l'évaluation des performances d'un système de reconnaissance du locuteur basé sur les Modèles de Mélange Gaussiens **GMM** et les Coefficients Cepstraux à Fréquence Mel **MFCC**, en explorant deux aspects clés :

1. L'impact de la durée des segments audio **5s, 10s, 15s** sur la précision de l'identification.
2. L'influence du nombre de composantes gaussiennes **8 à 256** dans les modèles **GMM** sur les taux d'erreur.

Objectifs

- Prétraiter les signaux audio en **supprimant les silences** et en extrayant les **MFCC**.
- Entraîner des modèles **GMM** avec différentes complexités 8 à 256 gaussiennes pour chaque locuteur.
- Évaluer les performances via : Le Taux de Bonne Identification **TBI** pour la tâche d'identification, et le Taux d'Erreur d'Égalité **TEE/EER** pour la vérification.
- Comparer les résultats selon la durée des segments et la configuration des **GMM**.

Bibliothèques utilisées

- **librosa** : utilisé pour charger les fichiers audio et d'extraire les **MFCC**.
- **webrtcvad** : bibliothèque de Voice Activity Detection (VAD) développée par Google. Sert à détecter et supprimer les parties silencieuses ou non vocales dans les signaux audio.
- **numpy** : utilisé pour les opérations numériques et la manipulation des matrices **MFCC**.
- **soundfile** : permet d'enregistrer les fichiers audio après traitement.
- **scikit-learn** (`sklearn.mixture.GaussianMixture`) : utilisé pour entraîner des modèles **GMM** pour chaque locuteur.
- **joblib** : Permet de sauvegarder les modèles **GMM** entraînés sous forme de fichiers.
- **os** : utilisé pour parcourir les répertoires de données et créer les dossiers de sortie.

2. Présentation de la base de données

Le dataset utilisé dans cette étude contient des enregistrements vocaux provenant de **23** locuteurs répartis comme suit :

- **13 femmes** (identifiées par des codes tels que F1, F2, ..., F13).
- **10 hommes** (identifiés par H1, H2, ..., H10).


Chaque locuteur dispose d'une structure de données organisée en deux sous-dossiers principaux :

1. Train :

- Contient un seul fichier audio de 2 minutes d'enregistrement.
- Utilisé pour l'entraînement des modèles GMM.

2. Test :

- Subdivisé en **3** catégories de segments audio de durées variables :
 - **5** fichiers de **5 secondes** chacun.
 - **5** fichiers de **10 secondes** chacun.
 - **5** fichiers de **15 secondes** chacun.
- Permet d'évaluer la robustesse du système selon la durée des échantillons.



3. Prétraitement des données audio

Le prétraitement des signaux audio est une étape essentielle avant toute tâche d'identification ou de vérification de locuteur. Il permet d'améliorer la qualité des caractéristiques extraites en supprimant les parties non pertinentes des enregistrements, comme les silences, et en normalisant les conditions d'analyse.

3.1 Suppression du silence

Pour nettoyer les enregistrements vocaux et supprimer les segments silencieux ou non vocaux, nous avons utilisé le module **WebRTC VAD** (Voice Activity Detection). Cet outil, développé par Google, permet de détecter avec précision les trames contenant de la parole dans un signal audio.

Le traitement suit les étapes suivantes :

- Le signal est d'abord découpé en trames fixes de 30 ms à l'aide de la fonction `frame_generator`.
- Chaque trame est convertie en format PCM 16 bits, nécessaire au fonctionnement du VAD.

- Le VAD analyse chaque trame et ne conserve que celles identifiées comme contenant de la parole.
- Enfin, les trames vocales sont concaténées pour former un signal épuré, sans silence.

3.2 Extraction des coefficients MFCC

Après la suppression des silences, les signaux nettoyés sont utilisés pour l'extraction des coefficients cepstraux en fréquence Mel **MFCC**, qui représentent la forme spectrale de la voix humaine en tenant compte de la perception auditive.

L'extraction des MFCC est réalisée via la bibliothèque **Librosa**, selon les étapes suivantes :

- Découpage en trames.
- Application d'une fenêtre de Hamming.
- Transformée de Fourier et passage par une banque de filtres de Mel.
- Calcul du logarithme des énergies et application de la Transformée en Cosinus Discrète (DCT).

Nous avons extrait **13 coefficients**, tout en supprimant le premier (représentant l'énergie globale de la trame) pour se focaliser sur les composantes spectrales. De plus, les trames à faible énergie sont ignorées pour éviter l'influence de segments peu informatifs ou bruités.

4. Modélisation par GMM : Entraînement

L'objectif de cette étape est de construire un modèle statistique capable de capturer les caractéristiques acoustiques de chaque locuteur à partir de ses coefficients MFCC. Pour cela, nous avons opté pour une approche basée sur les modèles de mélanges gaussiens (GMM - Gaussian Mixture Models).

4.1 Définition du modèle GMM

Un **GMM** est un modèle probabiliste qui représente la distribution des données comme une combinaison de plusieurs **gaussiennes**.

Chaque locuteur est modélisé indépendamment, en utilisant uniquement les vecteurs **MFCC** extraits de son dossier Train. L'algorithme Expectation-Maximization (**EM**) est utilisé pour estimer les paramètres des gaussiennes (moyennes, variances diagonales, poids).

4.2 Stratégie d'Entraînement

4.2.1 Préparation des données :

Les vecteurs MFCC extraits lors de l'étape de prétraitement sont organisés par locuteur. Chaque ensemble de données d'entraînement provient exclusivement des fichiers marqués 'Train'.

4.2.2 Entraînement multi-configurations :


Pour explorer la complexité des modèles, plusieurs GMM sont entraînés par locuteur avec différents nombres de composantes : **8, 16, 32, 64, 128 et 256**. Ce choix permet de comparer les performances des modèles simples (peu de gaussiennes) et complexes (plus de gaussiennes).

Les étapes de l'entraînement sont les suivantes :

- Parcours de chaque dossier de locuteur contenant les MFCC.
- Chargement des coefficients MFCC transposés (chaque vecteur MFCC est une colonne).
- Entraînement de plusieurs modèles GMM pour chaque locuteur, avec un nombre croissant de composantes via la classe **GaussianMixture** de la bibliothèque scikit-learn.
- Sauvegarde des modèles entraînés au format .pkl pour une réutilisation lors de la phase de test.

4.2.3 Sauvegarde des modèles :

Sauvegarde des modèles entraînés au format .pkl via **joblib** pour une réutilisation lors de la phase de test. On a une organisation par dossier locuteur.



5. Evaluation : Identification du Locuteur

L'évaluation de la performance du système d'identification du locuteur a été réalisée en utilisant la phase de test des fichiers MFCC extraits, ainsi que les modèles GMM entraînés précédemment.

5.1 Principe de l'identification

L'**identification** consiste à déterminer quel locuteur parmi un ensemble connu a prononcé une séquence audio donnée.

Pour cela, chaque fichier audio de test est comparé aux modèles GMM de tous les locuteurs disponibles du même genre que celui du locuteur du fichier audio. Le modèle qui donne la plus grande vraisemblance (log-likelihood) est sélectionné comme étant celui du locuteur reconnu.

5.2 Démarche

- Pour chaque fichier MFCC de test, on calcule la **log-vraisemblance** de ses caractéristiques vis-à-vis de chaque GMM du même genre.
- Le locuteur prédit est celui associé au score le plus élevé.
- On compare ensuite le locuteur prédit avec le locuteur réel afin de calculer le taux de reconnaissance.

5.3 Mesure de performance

Afin de mesurer la performance des modèles GMM, le calcul de la **TBI** a été effectué. Le Taux de Bonne Identification (TBI) est défini comme suit :

$$\text{TBI} = \frac{\text{Nombre de bonnes identifications}}{\text{Nombre total de tests}}$$

5.4 Résultats obtenus

Des tests ont été réalisés avec différents nombres de composantes dans les GMM : **8, 16, 32, 64**, etc.), afin d'observer l'impact de la complexité du modèle sur les performances.

Les résultats sont présentés sous forme de tableau ou de graphique, montrant l'évolution du TBI selon le nombre de composantes.

TBI	GMM 8	GMM 16	GMM 32	GMM 64	GMM 128	GMM 256	MOY
5s	71.30 %	71.30 %	72.17 %	71.30 %	72.17 %	73.91 %	72.02 %
10s	75.65 %	75.65 %	75.65 %	77.39 %	73.91 %	74.78 %	75.50 %
15s	83.47 %	83.47 %	84.34 %	84.34 %	84.34 %	81.73 %	83.61 %
MOY	76.80 %	76.80 %	77.38 %	77.67 %	76.80 %	76.80 %	--







5.5 Visualisation des performances

5.5.1 TBI plots par composantes :

Afin de mieux analyser l'impact du nombre de composantes du GMM et de la durée des segments audio sur les performances d'identification, des **graphes** ont été générés.

- Pour chaque nombre de composantes **8, 16, 32, 64, 128, 256** un graphique a été produit.
- L'axe des abscisses représente la durée des segments de test **5s, 10s, 15s**.
- L'axe des ordonnées indique la valeur du **TBI** obtenue.

Chaque courbe permet donc de visualiser l'évolution de la précision d'identification en fonction de la durée du segment pour un nombre de composantes donné.






5.5.2 TBI plots par segments :

En complément de l'analyse précédente, une seconde série de graphiques a été générée afin de fixer la durée des segments de test, et d'observer l'évolution du TBI en fonction du nombre de composantes du GMM.

- Pour chaque durée de segment **5s, 10s, 15s**, un graphique distinct est créé.
- L'axe des abscisses correspond au nombre de **composantes** utilisé pour le GMM.
- L'axe des ordonnées affiche la valeur du **TBI** atteinte.

Ces graphes offrent une autre perspective sur les performances du système d'identification, en mettant l'accent sur l'impact de la complexité du modèle.



5.5 Analyse des résultats

5.5.1 Influence de la durée des segments :

On observe une amélioration claire du TBI lorsque la durée du segment de test augmente :

- Segments de **5 secondes** : TBI compris entre **71.3%** et **73.9%**.
- Segments de **10 secondes** : TBI légèrement plus élevé, variant entre **73.9%** et **77.4%**.
- Segments de **15 secondes** : Meilleures performances, avec des TBI allant jusqu'à **84.3%**.

Conclusion : Plus le segment est long, plus le modèle dispose d'informations pour prendre une décision fiable.

5.5.2 Influence du nombre de composants :

Peu de composantes 8 ou 16 :

- Performances assez similaires pour toutes les durées (TBI max = 83.4% pour 15s).
- Le modèle est simple et peut manquer de capacité pour modéliser la complexité vocale.

Nombre moyen de composantes 32 ou 64 :

- Légère amélioration, notamment à 15s (TBI = 84.3%).
- Ces modèles offrent un bon compromis entre performance et complexité.

Modèles plus complexes 128 ou 256 :

- Les résultats restent élevés à 15s (84.3% avec 128 composantes), mais régressent légèrement à 256 (81.7%).
- On note même une baisse des performances pour 10s et 5s à 128 et 256 composantes.

Conclusion : Un nombre excessif de composantes peut entraîner un surapprentissage (overfitting), en particulier avec des segments courts. Le modèle devient trop spécifique aux données d'entraînement et généralise mal.

5.6 Conclusion

Pour un compromis optimal, l'utilisation de **32 à 64** composantes combinée à des segments de **15** secondes semble offrir les meilleurs résultats (TBI > 84%).

Si la durée du segment est contrainte, il est préférable de limiter la complexité du GMM (8 à 32 composantes), sans trop sacrifier la performance.

6. Evaluation : Vérification du Locuteur

Après avoir évalué notre système dans un cadre d'identification de locuteur, nous procédons maintenant à l'évaluation en vérification de locuteur, un scénario plus proche d'applications réelles.

6.1 Principe de la vérification

La **vérification** de locuteur consiste à confirmer ou infirmer l'identité revendiquée d'un locuteur, en comparant un échantillon de voix à un modèle préalablement entraîné pour cette personne. Il s'agit donc d'un problème binaire : accepter (authentification réussie) ou rejeter (authentification échouée) une identité déclarée.

6.2 Démarche

La procédure mise en œuvre repose sur les étapes suivantes :

- Chargement des **modèles GMM** pour chaque locuteur, pour différents nombres de composantes 8, 16, 32, 64, 128, 256.
- Pour chaque locuteur, on récupère ses segments de test de durées **5s, 10s et 15s**.
- Chaque segment est comparé à tous les modèles GMM du même genre (homme/femme).
- Pour chaque comparaison, on calcule un **score de vraisemblance** indiquant à quel point le segment correspond au modèle.
- Ces scores sont enregistrés avec l'identité réelle, l'identité proclamée, durée du segment, et nombre de composantes.
- Pour chaque configuration (composantes, segment), on fait varier un **seuil de décision** et on évalue :
 - **Les faux rejets (FR)** : vrais locuteurs rejetés
 - **Les fausses acceptations (FA)** : imposteurs acceptés
- En calculant le FAR (False Acceptance Rate) et le FRR (False Rejection Rate) pour chaque seuil, on déduit le EER.

6.3 Mesure de performance

Le **Equal Error Rate (EER)** représente le point d'équilibre entre le taux de fausses acceptations (FAR) et le taux de fausses rejets (FRR).

Plus la valeur du EER est **faible**, plus le système est **précis et fiable**.

Cette métrique est idéale pour juger un système de vérification, car elle offre une évaluation **neutre et standardisée** de ses performances.

6.4 Résultats obtenus



Les résultats sont les **EER** obtenus pour différentes durées de segments (5s, 10s, 15s) et différents nombres de composantes GMM (de 8 à 256).









EER	GMM 8	GMM 16	GMM 32	GMM 64	GMM 128	GMM 256	MOY
5s	0.2614	0.2379	0.2363	0.2279	0.2406	0.2339	0.2396
10s	0.3149	0.3188	0.3040	0.2967	0.2799	0.2751	0.2982
15s	0.2167	0.2069	0.2074	0.1994	0.2025	0.1944	0.2045
MOY	0.2643	0.2545	0.2492	0.2413	0.241	0.234	--









6.5 Visualisation des performances

6.5.1 Courbes DET :

À chaque configuration, une **courbe DET** (FAR/FRR) a été générée et le seuil optimal de EER a été déterminé.








6.5.1 Courbes EER :

Enfin, un **graphique global** a été tracé pour montrer l'évolution du **EER** en fonction du nombre de composantes, pour chaque durée de segment.



6.5 Analyse des résultats

6.5.1 Influence de la durée des segments :

- Contre-intuitivement, les performances sont **moins bonnes pour les segments de 10s** que pour 5s dans plusieurs cas. Cela peut être dû à une variabilité plus marquée dans les segments de 10s comme le contenu vocal, le bruit, etc..
- Les **segments de 15s donnent les meilleurs résultats**, avec des EER souvent inférieurs à 0.21. Cela s'explique par une quantité d'information plus riche, permettant un meilleur appariement avec les modèles GMM.

6.5.2 Influence du nombre de composants :

La **précision s'améliore** en général avec l'**augmentation du nombre de composantes**, car le modèle devient plus expressif et peut capturer davantage de nuances dans les données MFCC.

Au-delà de **64 ou 128 composantes**, le gain devient minimal. La complexité supplémentaire peut aussi accroître le risque de sur-apprentissage, surtout si les données ne sont pas très nombreuses ou homogènes, donc elle n'est pas nécessaire.

Pour chaque durée, le modèle à **256 composantes** est celui qui donne le **meilleur EER**, confirmant que plus de composantes permet une modélisation plus fine.

Les valeurs de **EER les plus bas** sont atteints avec les segments de **15 secondes**, quelle que soit la complexité du modèle.

La courbe EER en fonction du nombre de composantes montre :

- Une **baisse continue** de l'EER pour les segments de 15s quand on augmente les composantes.
- Une **stagnation autour de 32 à 64 composantes** pour les segments de 5s et 10s.
- Une **légère hausse du EER à 128 composantes** pour les segments de 10s : bruit possible ou manque de stabilité sur les données.

6.6 Conclusion

Les segments plus longs (15s) sont nettement meilleurs pour la vérification vocale, grâce à une richesse phonétique plus exploitable.

Le nombre de composantes optimal semble être **256**, en particulier pour des segments longs.

Un compromis optimal serait probablement d'utiliser 64 ou 128 composantes avec des segments de 15s, pour réduire le temps de calcul tout en gardant une bonne performance.

7. Conclusion

Dans le cadre de ce projet, nous avons mis en œuvre un système de **reconnaissance et de vérification de locuteur** en utilisant des modèles de mélanges gaussiens **GMM** et des coefficients cepstraux en fréquences Mel **MFCC**. L'objectif était d'une part, évaluer la capacité du système à identifier automatiquement un locuteur parmi un ensemble connu, et d'autre part, à vérifier si un locuteur est bien celui qu'il prétend être.

Les expérimentations menées ont permis de constater que les performances varient en fonction de deux paramètres essentiels : la **durée des segments** audio analysés et le **nombre de composantes gaussiennes** utilisées dans les GMM.

Pour la tâche d'**identification**, les résultats montrent clairement que les performances augmentent avec la durée des segments. De même, l'augmentation du nombre de composantes GMM améliore le Taux de Bonne Identification **TBI** jusqu'à 32 composantes, ensuite elle le diminue démontrant un sur-apprentissage. Concernant la **vérification**, nous avons utilisé comme mesure principale le taux d'erreur égal **EER**. Les résultats révèlent que le système atteint ses meilleures performances de vérification pour les segments longs et un nombre de composantes élevé.

Dans l'ensemble, ce travail démontre que des méthodes classiques telles que les MFCC couplés aux GMM restent pertinentes et efficaces pour des systèmes de **reconnaissance vocale**, surtout lorsqu'elles sont bien paramétrées. Ainsi, ce projet a permis de mettre en évidence les facteurs clés influençant les performances d'un système de reconnaissance de locuteur, tout en offrant une base solide pour des améliorations futures.